

Self-Corrective RAG

- **검색 결과 자기평가·재시도**



1. Self-Corrective 구현



1. Self-Corrective RAG란?

Self-Corrective RAG는 RAG 시스템이 검색 결과를 스스로 평가하고, 검색 결과가 질문에 충분히 관련되지 않거나 부족하다고 판단하면 검색 전략을 수정하여 다시 검색하는 방식이다.

일반적인 RAG는 검색 결과가 좋지 않아도 그대로 LLM에 전달한다.

사용자 질문



검색



검색 결과



LLM




답변



검색 결과가 부족하면 최종 답변의 품질도 떨어질 수 있다.

Self-Corrective RAG에서는 검색 결과를 한 번 더 평가하는 단계를 추가한다.



핵심은 "검색 결과를 그대로 믿지 않고 스스로 검증한다"는 것이다.

2. 왜 Self-Corrective RAG가 필요한가?

Vector Search를 사용한다고 해서 항상 정확한 문서가 검색되는 것은 아니다.

예를 들어 사용자가 다음과 같이 질문한다고 하자.

"토마토 위에 황색 반점이 나타나는 주요 원인과 방제 방법은?"

검색 결과가 다음과 같다고 가정한다.

검색 결과 1

토마토의 일반적인 재배 방법

검색 결과 2

토마토의 생육 온도 관리

검색 결과 3

토마토 잎의 곰팡이성 병해

질문과 직접적으로 관련된 정보는 검색 결과 3에 집중되어 있다.

일반적인 RAG는 검색 결과를 그대로 LLM에게 전달할 수 있다.

하지만 Self-Corrective RAG는 다음과 같이 판단할 수 있다.

검색 결과 평가



관련성이 낮은 문서가 많음



현재 검색 결과 부족



질문 수정




재검색

따라서 검색 결과의 품질이 낮을 때 자동으로 보정할 수 있다.

3. Self-Corrective RAG의 핵심 구조

Self-Corrective RAG의 기본 구조는 다음과 같다.



여기서 중요한 구성 요소는 다음 세 가지이다.

Retriever

→ 관련 문서 검색

Grader

→ 검색 결과의 관련성 평가

Query Rewriter

→ 검색 결과가 부족하면 질문을 수정

4. 검색 결과 평가

Self-Corrective RAG에서는 검색 결과를 LLM 또는 별도의 평가 모델이 판단할 수 있다.

예를 들어 질문이 다음과 같다고 하자.

"HBM이 AI 가속기에 사용되는 이유는?"

검색 결과:

문서 A

HBM은 고대역폭 메모리이다.

문서 B

HBM은 AI 가속기의 대규모 데이터 처리에 활용된다.

문서 C

DRAM의 일반적인 구조와 동작 원리

검색 결과 평가기는 각 문서가 질문에 얼마나 관련되는지 판단할 수 있다.

문서 A → 관련

문서 B → 매우 관련

문서 C → 관련성 낮음

또는 전체 검색 결과를 하나의 기준으로 평가할 수도 있다.

질문과 검색 결과의 관련성



충분함 → 답변

부족함 → 재검색

5. Query Rewriting

검색 결과가 부족하면 단순히 같은 질문으로 다시 검색하는 것이 아니라 질문을 수정할 수 있다.

이를 Query Rewriting이라고 한다.

예를 들어 원래 질문이 다음과 같다고 하자.

"HBM이 AI에 좋은 이유는?"

검색 결과가 부족하다면 다음과 같이 검색어를 구체화할 수 있다.

원래 질문

HBM이 AI에 좋은 이유는?



수정된 검색 질문

HBM 고대역폭 메모리 AI 가속기 데이터 처리 장점

다시 검색한다.

수정된 Query
↓
Vector Search
↓
새로운 검색 결과
↓
결과 평가

이러한 과정을 통해 처음 검색에서 놓친 정보를 다시 찾을 수 있다.

6. Self-Corrective RAG의 반복 구조

Self-Corrective RAG는 필요하면 검색을 여러 번 수행할 수 있다.

질문
↓
1차 검색
↓
결과 평가
↓
부족
↓
Query 수정
↓
2차 검색
↓
결과 평가
↓
충분
↓
LLM
↓
답변

따라서 검색 횟수가 고정되어 있지 않다.

다만 무한히 검색하는 것을 방지하기 위해 최대 재시도 횟수 등을 설정할 필요가 있다.

예:

최대 검색 횟수 = 3회

1차 검색 → 부족

2차 검색 → 부족

3차 검색 → 최종 결과 사용

7. Self-Corrective RAG와 Agentic RAG의 차이

두 기술은 비슷해 보이지만 초점이 다르다.

Agentic RAG의 핵심은

| "어떤 검색 전략을 사용할 것인가?"

이다.

Self-Corrective RAG의 핵심은

| "검색 결과가 충분하고 올바른가?"

이다.

비교하면 다음과 같다.

구분	Agentic RAG	Self-Corrective RAG
핵심 목적	검색 전략 결정	검색 결과 보정
주요 판단	어떤 Tool을 사용할 것인가?	검색 결과가 충분한가?
핵심 기능	Tool 선택	결과 평가 및 재검색
재검색	필요에 따라 수행	평가 결과가 부족하면 수행
핵심 개념	자율 검색	자기 평가·수정

두 기술을 결합할 수도 있다.

사용자 질문



Agent



검색 전략 결정



검색



결과 평가



부족



Query 수정



Agent가 다음 검색 전략 결정



재검색



답변

8. Self-Corrective RAG의 장점

① 잘못된 검색 결과를 그대로 사용하지 않는다

검색 결과를 평가하는 단계를 추가하여 관련성이 낮은 결과를 걸러낼 수 있다.

② 검색 실패에 대응할 수 있다

검색 실패
↓
Query 수정
↓
재검색



③ 질문 표현이 부정확해도 보완할 수 있다

사용자의 질문이 너무 짧거나 모호한 경우 Query Rewriting을 통해 보다 검색하기 좋은 형태로 변경할 수 있다.

④ RAG의 신뢰성을 높일 수 있다

검색 결과가 충분한지 확인한 후 LLM에게 전달하기 때문에 단순 RAG보다 안정적인 검색 파이프라인을 구성할 수 있다.

9. Self-Corrective RAG의 한계

Self-Corrective RAG 역시 추가적인 LLM 호출과 검색이 필요하다.

검색
↓
평가
↓
재작성
↓
재검색
↓
평가

따라서 일반적인 RAG보다 비용과 응답 시간이 증가할 수 있다.

또한 평가 모델이 잘못 판단하면 다음과 같은 문제가 발생할 수 있다.


실제로 좋은 검색 결과
↓
평가기가 "부족함"으로 판단
↓
불필요한 재검색

반대로 좋지 않은 검색 결과를 충분하다고 잘못 판단할 수도 있다.

따라서 Grader의 평가 기준을 적절하게 설계하는 것이 중요하다.

10. Self-Corrective RAG의 전체 흐름

전체 과정을 정리하면 다음과 같다.



핵심 구조는 다음 세 단계이다.

Retrieve
↓
Grade
↓
Correct

즉,

검색한다
→ 평가한다
→ 부족하면 수정한다
→ 다시 검색한다

라는 반복 구조가 Self-Corrective RAG의 핵심이다.

11. 네 가지 고급 RAG 기법과의 관계

지금까지 학습한 네 가지 기법을 하나의 흐름으로 비교하면 다음과 같다.

Graph RAG

→ 관계를 이용하여 검색

Agentic RAG

→ 검색 전략을 Agent가 결정

Self-Corrective RAG

→ 검색 결과를 평가하고 부족하면 재검색

RAG Fusion

→ 여러 검색 결과를 결합

이를 한 문장씩 기억하면 다음과 같다.

기술

핵심 질문



Graph RAG

"무엇과 어떻게 연결되어 있는가?"

Agentic RAG

"어떤 검색 방법을 사용할 것인가?"

Self-Corrective RAG

"검색 결과가 충분한가?"

RAG Fusion

"여러 검색 결과를 어떻게 결합할 것인가?"

따라서 Self-Corrective RAG의 핵심은 "검색 결과를 한 번 받고 끝내는 것이 아니라, 결과를 스스로 평가하여 부족하면 검색 과정을 수정하고 다시 시도하는 것"이다.



감사합니다