

RAG Fusion

- **앙상블 검색 통합 기법**



1. RAG Fusion 구현



1. RAG Fusion이란?

RAG Fusion은 하나의 질문을 여러 개의 검색 질문으로 변환하고, 각각의 검색 결과를 통합하여 더 관련성이 높은 문서를 찾는 검색 기법이다.

일반적인 RAG에서는 하나의 질문으로 한 번 검색한다.

사용자 질문



Query



Vector Search



검색 결과



LLM




답변



하지만 하나의 질문만으로 검색하면 질문의 특정 표현이나 관점에 따라 관련 문서를 놓칠 수 있다.

RAG Fusion에서는 하나의 질문을 여러 개의 Query로 확장한다.



핵심은 여러 검색 결과를 단순히 합치는 것이 아니라, 서로 다른 검색 결과를 통합하여 최종 검색 품질을 높이는 것이다.

2. 왜 RAG Fusion이 필요한가?

사용자의 질문은 하나의 표현으로 작성되지만, 문서에서는 다양한 표현으로 나타날 수 있다.

예를 들어 질문이 다음과 같다고 하자.

"생성형 AI가 기업 업무에 어떤 영향을 미치는가?"

관련 문서는 다음과 같은 표현을 사용할 수 있다.

문서 A

생성형 AI의 기업 업무 활용

문서 B

기업의 업무 자동화와 LLM

문서 C

생성형 인공지능 도입에 따른 생산성 변화

문서 D

AI 기반 업무 혁신 사례

하나의 Query만 사용하면 특정 표현과 유사한 문서만 높은 순위에 나타날 수 있다.

RAG Fusion은 질문을 여러 관점으로 확장한다.

원래 질문

생성형 AI가 기업 업무에 어떤 영향을 미치는가?



Query 1

생성형 AI의 기업 업무 활용

Query 2

생성형 AI가 업무 생산성에 미치는 영향

Query 3

LLM 기반 업무 자동화 사례

Query 4

기업의 생성형 AI 도입 효과

각 Query로 검색한 결과를 통합하면 다양한 표현을 사용하는 관련 문서를 함께 찾을 수 있다.

3. Multi-Query와 RAG Fusion

RAG Fusion은 Multi-Query Retrieval과 밀접한 관계가 있다.

Multi-Query는 하나의 질문을 여러 개의 검색 Query로 확장하는 방법이다.

사용자 질문



LLM



Q1



Q2



Q3



검색



검색



검색

RAG Fusion은 여기에서 한 단계 더 나아가 각각의 검색 결과를 통합하고 순위를 다시 정리한다.

Multi-Query
↓
여러 Query 생성
↓
각각 검색
↓
RAG Fusion
↓
검색 결과 통합
↓
최종 순위 결정

따라서 다음과 같이 구분하면 이해하기 쉽다.

Multi-Query
→ "질문을 여러 개로 만들어 검색한다."


RAG Fusion
→ "여러 검색 결과를 하나의 결과 목록으로 통합한다."

4. RAG Fusion의 전체 처리 과정

RAG Fusion의 일반적인 처리 과정은 다음과 같다.

- ① 사용자 질문
- ↓
- ② 여러 Query 생성
- ↓
- ③ 각각의 Query로 검색
- ↓
- ④ 검색 결과 수집
- ↓
- ⑤ 검색 결과 통합
- ↓
- ⑥ 문서 순위 재정렬
- ↓
- ⑦ 상위 문서 선택
- ↓
- ⑧ LLM에 Context 전달
- ↓
- ⑨ 답변 생성

이를 그림으로 표현하면 다음과 같다.



5. 검색 결과를 어떻게 통합하는가?

여러 검색 결과를 단순히 이어 붙이면 동일한 문서가 여러 번 등장하거나 검색 순위가 서로 달라 문제가 발생할 수 있다.

예를 들어 다음과 같은 검색 결과가 있다고 하자.

Query 1

1위 문서 A

2위 문서 B

3위 문서 C

Query 2

1위 문서 B

2위 문서 D

3위 문서 A

Query 3

1위 문서 A

2위 문서 D

3위 문서 E



여기에서 문서 A는 여러 Query에서 반복적으로 높은 순위를 차지한다.

여기에서 문서 A는 여러 Query에서 반복적으로 높은 순위를 차지한다.

문서 A

- Query 1 : 1위
- Query 2 : 3위
- Query 3 : 1위

따라서 여러 검색 결과에서 반복적으로 높은 순위를 차지하는 문서를 우선적으로 선택할 수 있다.

이때 대표적으로 사용하는 방법이 RRF(Reciprocal Rank Fusion)이다.

6. RRF(Reciprocal Rank Fusion)

RRF는 여러 검색 결과의 순위를 이용하여 최종 순위를 계산하는 방법이다.

기본 아이디어는 간단하다.

여러 검색 결과에서 반복적으로 높은 순위를 차지하는 문서에 높은 점수를 부여한다.

개념적인 점수 계산은 다음과 같다.

$$\begin{aligned} &\text{RRF Score}(d) \\ &= \\ &\sum 1 / (k + \text{rank}(d)) \end{aligned}$$

여기서

- d : 문서
- $\text{rank}(d)$: 해당 검색 결과에서 문서의 순위
- k : 순위가 너무 높은 결과에 점수가 과도하게 집중되는 것을 완화하는 상수이다.

예를 들어 어떤 문서가 여러 Query에서 다음과 같은 순위를 기록했다고 하자.

Query 1 → 1위

Query 2 → 3위

Query 3 → 2위



여러 검색 결과에서 반복적으로 높은 순위를 차지했기 때문에 최종적으로 높은 순위를 받을 가능성이 높다.

RRF의 장점은 서로 다른 검색 시스템의 점수 체계가 달라도 "순위"를 기준으로 결과를 통합할 수 있다는 점이다.

7. RAG Fusion의 예

질문:

"생성형 AI를 활용한 기업 업무 자동화 방법은?"

Query Generator가 다음 세 가지 Query를 생성했다고 하자.

Query 1

생성형 AI 기업 업무 자동화

Query 2

LLM 업무 자동화 활용 사례

Query 3

생성형 AI 기반 업무 혁신

각각 검색한다.

Query 1

A → B → C

Query 2

B → D → E

Query 3

A → D → F

검색 결과를 통합하면

A

B

C

D

E

F

검색 결과를 통합하면

A
B
C
D
E
F

가 되고, 여러 Query에서 반복적으로 등장하거나 높은 순위를 차지한 문서를 우선적으로 배치한다.

최종 결과

1위 A
2위 B
3위 D
4위 C
5위 E

이 중 상위 문서를 LLM의 Context로 전달한다.

8. RAG Fusion의 장점

① 검색 범위를 확장할 수 있다

하나의 Query가 놓칠 수 있는 다양한 표현을 검색할 수 있다.

하나의 Query



검색 범위 제한

여러 Query



다양한 표현과 관점 검색



② 검색 결과의 안정성을 높일 수 있다

여러 Query에서 반복적으로 검색되는 문서는 상대적으로 중요한 정보일 가능성이 높다.

③ 질문의 표현 차이를 보완할 수 있다

사용자가 "AI 업무 자동화"라고 질문해도 문서에는 "LLM 기반 업무 혁신"이라고 표현되어 있을 수 있다.

여러 Query를 생성하면 이러한 표현 차이를 보완할 수 있다.

④ 여러 검색 전략을 결합할 수 있다

RAG Fusion은 여러 검색기의 결과를 통합하는 방식으로 확장할 수 있다.

```
Query
├─ Vector Search
├─ BM25
├─ Keyword Search
└─ 다른 Retriever
    ↓
  Result Fusion
    ↓
  Reranking
```

따라서 단일 검색 방식의 한계를 보완할 수 있다.

9. RAG Fusion의 한계

① 검색 횟수가 증가한다

Query를 여러 개 생성하면 각각 검색해야 하므로 검색 비용이 증가한다.

1개 Query

→ 1회 검색

4개 Query

→ 4회 검색

따라서 Query 개수와 검색 대상 문서 수를 적절하게 조절해야 한다.

② Query 품질에 영향을 받는다

LLM이 의미가 비슷한 Query만 반복적으로 생성하면 검색 범위가 충분히 확장되지 않을 수 있다.

Q1 → AI 업무 자동화

Q2 → AI를 이용한 업무 자동화

Q3 → AI 업무 자동화 방법

서로 다른 Query처럼 보이지만 실제 검색 관점은 거의 동일하다.

③ 중복 결과가 많이 발생할 수 있다

여러 Query가 동일한 문서를 검색할 수 있으므로 결과를 통합할 때 중복 제거가 필요하다.

④ Reranking 비용이 추가될 수 있다

검색 결과가 많아지면 최종적으로 중요한 문서를 다시 선별하기 위한 Reranking 과정이 필요할 수 있다.

10. RAG Fusion과 다른 고급 RAG 기법 비교

네 가지 고급 RAG 기법을 비교하면 다음과 같다.

기술	핵심 개념	핵심 질문
Graph RAG	관계 기반 검색	"무엇과 어떻게 연결되어 있는가?"
Agentic RAG	검색 전략 자율 결정	"어떤 검색 방법을 사용할 것인가?"
Self-Corrective RAG	검색 결과 평가 및 재검색	"검색 결과가 충분한가?"
RAG Fusion	여러 검색 결과 통합	"여러 검색 결과를 어떻게 결합할 것인가?"



감사합니다